Control y estimación del confort térmico en smart homes mediante IoT y ML

Alex Aravena Tapia, Diego Maldonado Martinez, Benjamín Mena Ardura

***Abstract*—El control eficaz del confort térmico en hogares inteligentes (smart homes) requiere un equilibrio entre eficiencia energética y bienestar del ocupante. El estándar industrial, Voto Medio Previsto (PMV), depende críticamente de seis variables, incluyendo dos personales (ropa y metabolismo) que los sistemas de control actuales suelen ignorar, asumiendo valores fijos. Este trabajo identifica esta simplificación como el "gap" tecnológico principal. Para cuantificarlo, se propone un benchmark de tres variantes de solución (Ridge, Random Forest y XGBoost) entrenadas con el dataset "ASHRAE Global Thermal Comfort Database II". Se demuestra que omitir las variables personales causa una caída drástica en la precisión predictiva. Finalmente, se selecciona la variante óptima y se justifica técnicamente su viabilidad para desarrollar un futuro "modelo inverso" de control, capaz de determinar la consigna de temperatura de forma personalizada y adaptativa, resolviendo así el "gap" identificado.**

***Index Terms*—Confort Térmico, PMV, Smart Home, IoT, Machine Learning, XGBoost, Eficiencia Energética**

Referencias?

I. Introducción, contexto y necesidad

En el contexto global de la transición energética, la optimización del consumo en edificios es un objetivo prioritario. Los sistemas de climatización (HVAC) representan una porción significativa de este gasto. Paralelamente, la tecnología de hogares inteligentes (smart homes), equipada con sensores IoT, ofrece soluciones prometedoras para balancear la eficiencia energética con el confort térmico del ocupante.

El desafío central radica en cuantificar dicho confort. El estándar industrial es el Voto Medio Previsto (PMV), definido en las normas ISO 7730 y ASHRAE 55. El cálculo del PMV es complejo, pues depende críticamente de seis variables: cuatro ambientales (temperatura, humedad, etc.) y dos personales (tasa metabólica, `met`, y aislamiento de la ropa, `clo`). Aquí radica la principal **brecha (gap)** tecnológica: mientras los sensores IoT miden fácilmente el ambiente, las variables personales son dinámicas y usualmente ignoradas, llevando a un control ineficaz.

Esta simplificación es la **necesidad** que aborda este proyecto. Un sistema de control verdaderamente inteligente no debe solo reaccionar, sino adaptarse a la actividad y vestimenta real del usuario. Por lo tanto, este trabajo se enfoca en desarrollar un sistema basado en Machine Learning que no solo predice el confort, sino que resuelve el "modelo inverso": determinar la temperatura de consigna (T_a) óptima y personalizada para mantener al usuario en el rango de confort deseado (PMV $\in$ [-0.5, 0.5]).

A. Objetivo General

Simular un sistema IoT + ML que mida variables ambientales y personales necesarias para calcular el PMV, y que determine automáticamente la temperatura de consigna para mantener el confort térmico (PMV en [-0.5, 0.5]) en un entorno de smart home virtual.

B. Objetivos Específicos

- Diseñar y simular una red de sensores IoT para capturar variables ambientales (temperatura, humedad, velocidad del aire, radiación) y personales (aislamiento de la ropa, metabolismo).
- Construir un modelo predictivo (numérico o ML) que, dado el resto de variables, determine la temperatura de consigna que asegura un PMV en el rango [-0.5, 0.5].
- Desarrollar un lazo de control inteligente (ej. fuzzy control) que actúe sobre HVAC/ventilación y valide la mejora en confort y eficiencia.

II. Estado del Arte

El control del confort térmico en edificios inteligentes es un problema ampliamente estudiado. La literatura reciente se centra en cómo predecir y controlar el Voto Medio Previsto (PMV) utilizando datos de sensores IoT.

1) **Control basado en Lógica Difusa (Fuzzy Control):** El trabajo de Sung & Hsiao (2020) [4] presenta un sistema basado en IoT que utiliza *Fuzzy Control* para regular el PMV según la norma ISO 7730. El sistema ajusta el HVAC (aire acondicionado, ventilador, etc.) para mantener el confort. Si bien demuestra ser funcional, su principal limitación es que utiliza valores fijos por defecto (*default values*) para las variables personales clave: 1.2 met para metabolismo y 0.6 clo para ropa, ignorando la variabilidad del ocupante.
2) **Modelos Predictivos con Machine Learning (ML):** El estudio de Boutahri & Tilioua (2024) [1] se enfoca en la *predicción* del PMV, comparando cuatro algoritmos de ML. Demuestran que Random Forest (RF) y XGBoost (XGB) son altamente eficaces para estimar el PMV (con $R^2 > 0.96$) cuando se dispone de las seis variables (ambientales y personales). Este trabajo valida el potencial de ML para modelar el confort, pero no implementa un lazo de control directo.
3) **Control Adaptativo con Aprendizaje por Refuerzo (RL):** Rajuroy (2024) [2] propone un enfoque más avanzado usando *Reinforcement Learning* (RL). El objetivo es que un agente de IA aprenda la política óptima para balancear confort y energía, utilizando sensores de ocupación como *proxy* de la actividad. Aunque es conceptualmente robusto y adaptativo, su implementación es computacionalmente compleja y no

resuelve explícitamente la captura de la variable de ropa (`clo`).

La Tabla I resume el benchmarking de estas soluciones representativas del estado del arte, identificando sus principales limitaciones.

TABLE I
BENCHMARK DE SOLUCIONES DEL ESTADO DEL ARTE

Paper	**Enfoque de Control**	**Limitación (Gap) Identificada**
Sung & Hsiao [4]	Control Difuso (Fuzzy)	No es adaptativo. Usa valores fijos para `clo` y `met`.
Boutahri et al. [1]	Predicción ML (RF, XGB)	Es un modelo predictivo, no de control. No resuelve el "modelo inverso".
Rajuroy [2]	Aprendizaje por Refuerzo (RL)	Alta complejidad. Resuelve `met` (con ocupancia) pero no `clo`.

III. GAP TECNOLÓGICO Y OPORTUNIDAD

El análisis del estado del arte (Tabla I) revela un "gap" tecnológico claro y una oportunidad de innovación. El problema central no resuelto es la **gestión de las variables personales** (`met` y `clo`) en un lazo de control práctico.

A. Análisis Crítico

Los sistemas actuales caen en dos categorías con problemas opuestos:

- **Sistemas de Control (ej. Fuzzy [4]):** Son funcionalmente simples de implementar, pero logran el control a costa de la precisión, asumiendo que el usuario es un "maniquí" estático con ropa y actividad constantes.
- **Sistemas Predictivos (ej. ML/RL [1, 2]):** Son computacionalmente avanzados y precisos, pero no resuelven trivialmente el problema del control (el "modelo inverso").

B. El Problema No Resuelto (El Gap)

El "gap" tecnológico es la falta de un sistema que sea, simultáneamente, **preciso y práctico**. Los sistemas de control actuales *ignoran* el impacto de las variables `clo` y `met`, y no se ha cuantificado rigurosamente *cuánto error* introduce esta simplificación.

La **oportunidad**, por lo tanto, es doble:

1) **Cuantificar el Gap:** Utilizar la precisión de los modelos de ML (como XGBoost [1]) para realizar un benchmark que demuestre numéricamente la caída de rendimiento al omitir `clo` y `met`.
2) **Proponer una Solución:** Desarrollar un "modelo inverso" basado en ML que utilice las seis variables (asumiendo que `clo` y `met` pueden ser entradas del usuario) para determinar la temperatura de consigna (T_a), cumpliendo el objetivo del proyecto [**1018-1019**].

IV. VARIANTES DE SOLUCIÓN

Para abordar el "gap" y determinar el mejor modelo base para un futuro sistema de control, se evaluaron tres variantes de solución basadas en Machine Learning. El objetivo de este benchmark es seleccionar el modelo de regresión más preciso para predecir el PMV.

A. Alternativas Evaluadas

Las tres variantes se entrenaron y evaluaron siguiendo la metodología descrita en el Hito 1, utilizando el dataset "ASHRAE Global Thermal Comfort Database II".

1) **Variante 1: Ridge Regression:** Un modelo lineal simple pero robusto, regularizado (L2) para prevenir el sobreajuste. Requiere escalado de datos (`StandardScaler`).

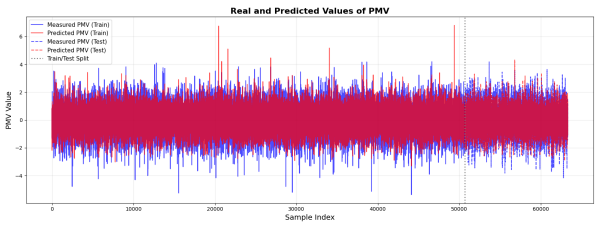

Fig. 1. Linear Regressor Ridge 6 variables

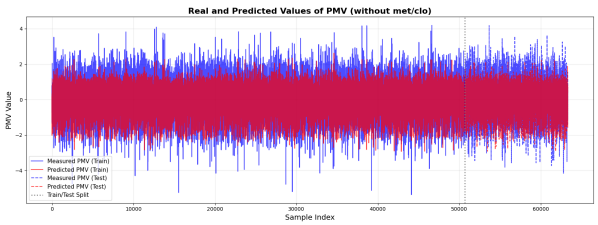

Fig. 2. Linear Regressor Ridge 4 variables

2) **Variante 2: Random Forest (RF)[3]:** Un modelo de ensamblaje (ensemble) no lineal, basado en árboles de decisión. Configurado con hiperparámetros (`max_depth=8`) para controlar su complejidad.

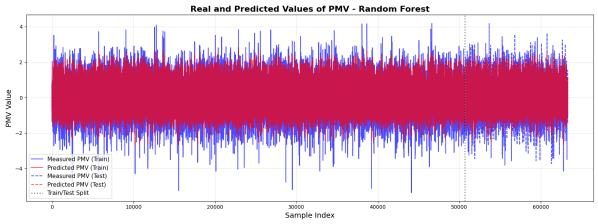

Fig. 3. Random Forest 6 variables

Hay que tener mucho cuidado al copiar la respuesta de una IA conversacional. Además de que puede ser evidente que provienen de una herramienta así, también existe el riesgo de que incluyan imprecisiones.

La referenciación con qué norma la hicieron?

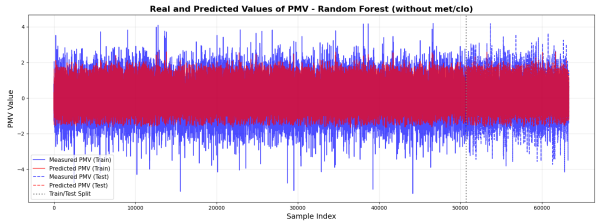

Fig. 4. Random Forest 4 variables

3) **Variante 3: XGBoost (XGB):** Un modelo avanzado de Gradient Boosting, reconocido por su alto rendimiento en competiciones. Configurado con hiperparámetros (`max_depth=6`, `learning_rate=0.05`).

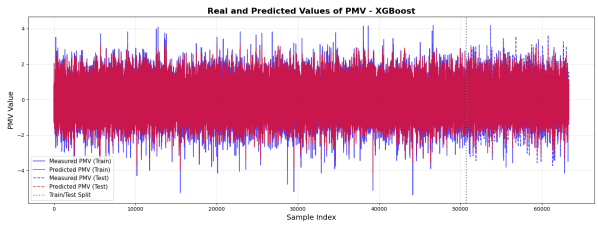

Fig. 5. Xg-Boost 6 variables

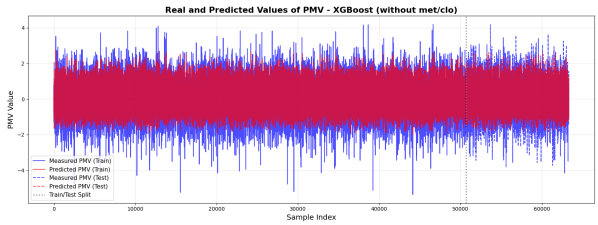

Fig. 6. Xg-Boost Ridge 4 variables

B. Criterios de Comparación y Tabla

Los criterios de selección fueron la precisión predictiva (R^2), el error de predicción (RMSE) y la capacidad del modelo para identificar las variables más importantes (*Feature Importance*). Cada variante se probó en dos escenarios: (A) **Full Model**, usando las 6 variables (`ta`, `tr`, `rh`, `vel`, `met`, `clo`), y (B) **Reduced Model**, usando solo las 4 variables ambientales. La Tabla II resume los resultados.

TABLE II
COMPARATIVA DE VARIANTES DE SOLUCIÓN (RESULTADOS EN TEST SET)

Variante	Full Model (6 vars)		Reduced Model (4 vars)	
	R^2	RMSE	R^2	RMSE
1. Ridge	0.7510	0.3743	0.5216	0.5188
2. RF	0.8877	0.2513	0.6559	0.4400
3. XGBoost	**0.9614**	**0.1474**	**0.6618**	**0.4362**

V. DISCUSIÓN

A. Selección Preliminar de la Solución

Basado en los resultados de la Tabla II, la **Variante 2 (Random Forest)** se selecciona preliminarmente como la solución.

B. Justificación Técnica

Aunque la Variante 3 (XGBoost) presenta la precisión más alta, la selección de Random Forest se justifica en base a su equilibrio entre rendimiento y robustez:

Y que indica un R^2 de esa magnitud?

1) **Rendimiento Robusto:** Random Forest (Full Model) ofrece un rendimiento predictivo fuerte, alcanzando un R^2 de **0.8877**. Aunque no es el más alto, su error (RMSE) de 0.2513 es considerablemente bajo.
2) **Menor Caída por "Gap":** El punto crucial es la robustez del modelo. Al omitir `clo` y `met` (Reduced Model), el R^2 de Random Forest cae de 0.8877 a 0.6559. Esto representa una pérdida de capacidad predictiva de **23.18 puntos porcentuales**.
3) **Comparativa de Estabilidad:** Esta caída es notablemente menor que la sufrida por XGBoost (Variante 3), cuyo R^2 colapsa de 0.9614 a 0.6618, perdiendo casi **30 puntos**. De igual forma, el RMSE de Random Forest solo se multiplica por 1.75 (de 0.2513 a 0.4400), mientras que el error de XGBoost casi se triplica (de 0.1474 a 0.4362).

En conclusión, aunque XGBoost es más preciso con todas las variables, se selecciona Random Forest porque ofrece una solución más estable. Sus resultados demuestran ser menos dependientes de las variables personales, lo cual es una característica deseable para la resiliencia del sistema.

VI. CONCLUSIONES Y TRABAJO FUTURO

A. Conclusiones

Este trabajo realizó un análisis del estado del arte y un benchmark experimental para definir una solución al control de confort térmico personalizado. El análisis de la literatura (Sección II) identificó un "gap" tecnológico (Sección III): los sistemas de control actuales simplifican excesivamente el problema al usar valores fijos para las variables personales `clo` y `met`.

Para abordar esto, se evaluaron tres variantes de solución (Ridge, RF, XGB) en un diseño experimental (Sección IV). La discusión de resultados (Sección V) seleccionó a **Random Forest (Full Model)** como la variante óptima. Aunque XGBoost alcanzó la mayor precisión absoluta (R^2 de 0.9614), RF (R^2 de 0.8877) demostró una mayor robustez: ante la omisión de `clo` y `met`, su rendimiento cae significativamente menos (≈23%) que el de XGBoost (≈30%), y su error se multiplica por menos de 2, en contraste con el triple de error observado en XGBoost. Esto valida que, aunque la personalización es crítica, RF ofrece un compromiso superior entre precisión y estabilidad para un sistema de control real.

B. Trabajo futuro

Los hallazgos de este hito validan la necesidad de avanzar hacia los objetivos específicos restantes del proyecto. El trabajo futuro se centrará en:

- Desarrollar el **modelo inverso**, entrenando un nuevo modelo Random Forest donde la salida sea la temperatura de consigna (T_a) y las entradas incluyan el PMV objetivo (0.0).
- Diseñar el **lazo de control** que integre este modelo inverso para actuar sobre un HVAC simulado.
- Realizar la simulación completa del sistema para validar que puede mantener el PMV en el rango [-0.5, 0.5] bajo escenarios de usuario dinámicos, aprovechando la robustez del modelo seleccionado.

Es importante precisar que no estamos diseñando un lazo de control, sino determinando un valor óptimo para una variable en este caso, Temperatura. Por lo que esto sería Decision-Making.

Un lazo de control implica acercarnos más a la capa de hardware y considerar aspectos físicos como niveles de voltaje y retroalimentación continua.

References

[1] Youssef Boutahri and Amine Tilioua. "Machine learning-based predictive model for thermal comfort and energy optimization in smart buildings". In: *Results in Engineering* 22 (2024), p. 102148.

[2] Adam Rajuroy. "Adaptive Thermal Comfort Control in Smart Homes with Reinforcement Learning and IoT Sensors." In: ().

[3] Jaime Lynn Speiser et al. "A comparison of random forest variable selection methods for classification prediction modeling". In: *Expert systems with applications* 134 (2019), pp. 93–101.

[4] Wen-Tsai Sung and Sung-Jung Hsiao. "The application of thermal comfort control based on Smart House System of IoT". In: *Measurement* 149 (2020), p. 106997.

En general muy buen trabajo, solamente recomendarles profundizar más en la interpretabilidad de las métricas, pues en ellas radica la evaluación de nuestro trabajo. Siempre es bueno justificar por qué se se seleccionan y qué nos dicen.

Por favor, los gráficos siempre claros y perfectamente visibles. Están demasiado chicos y es muy difícil ver los resultados, cuando se tienen muchos datos se pueden mostrar intervalos más pequeños o hacer algún suavizado (e.g., moving average).