Control y estimación del confort térmico en smart homes mediante IoT y ML

Alex Aravena Tapia, Diego Maldonado Martinez, Benjamín Mena Ardura

***Abstract*—El control eficaz del confort térmico en hogares inteligentes (smart homes) requiere un equilibrio entre eficiencia energética y bienestar del ocupante. El estándar industrial, Voto Medio Previsto (PMV), depende críticamente de seis variables, incluyendo dos personales (ropa y metabolismo) que los sistemas de control actuales suelen ignorar, asumiendo valores fijos. Este trabajo identifica esta simplificación como el "gap" tecnológico principal. Para cuantificarlo, se propone un benchmark de tres variantes de solución (Ridge, Random Forest y XGBoost) entrenadas con el dataset "ASHRAE Global Thermal Comfort Database II". Se demuestra que omitir las variables personales causa una caída drástica en la precisión predictiva. Finalmente, se selecciona la variante óptima y se justifica técnicamente su viabilidad para desarrollar un futuro "modelo inverso" de control, capaz de determinar la consigna de temperatura de forma personalizada y adaptativa, resolviendo así el "gap" identificado. [7]**

***Index Terms*—Confort Térmico, PMV, Smart Home, IoT, Machine Learning, XGBoost, Eficiencia Energética**

I. Introducción, contexto y necesidad

En el contexto global de la transición energética, la optimización del consumo en edificios es un objetivo prioritario. Los sistemas de climatización (HVAC) representan una porción significativa de este gasto. Paralelamente, la tecnología de hogares inteligentes (smart homes), equipada con sensores IoT, ofrece soluciones prometedoras para balancear la eficiencia energética con el confort térmico del ocupante.

El desafío central radica en cuantificar dicho confort. El estándar industrial es el Voto Medio Previsto (PMV), definido en las normas ISO 7730 y ASHRAE 55. El cálculo del PMV es complejo, pues depende críticamente de seis variables: cuatro ambientales (temperatura, humedad, etc.) y dos personales (tasa metabólica, `met`, y aislamiento de la ropa, `clo`). Aquí radica la principal **brecha (gap)** tecnológica: mientras los sensores IoT miden fácilmente el ambiente, las variables personales son dinámicas y usualmente ignoradas, llevando a un control ineficaz.

Esta simplificación es la **necesidad** que aborda este proyecto. Un sistema de control verdaderamente inteligente no debe solo reaccionar, sino adaptarse a la actividad y vestimenta real del usuario. Por lo tanto, este trabajo se enfoca en desarrollar un sistema basado en Machine Learning que no solo predice el confort, sino que resuelve el "modelo inverso": determinar la temperatura de consigna (T_a) óptima y personalizada para mantener al usuario en el rango de confort deseado (PMV $\in$ [-0.5, 0.5]).

A. Objetivo General

Desarrollar un sistema IoT + ML capaz de estimar la temperatura de aire óptima (T_a) que mantenga el confort térmico del ocupante dentro del rango recomendado (PMV $\in [-0.5, 0.5]$), utilizando únicamente variables ambientales y parámetros introducidos por el usuario, sin implementar un lazo de control HVAC.

B. Objetivos Específicos

- Diseñar y simular una red de sensores IoT para capturar las variables ambientales necesarias para la estimación del confort térmico (temperatura radiante, humedad relativa, velocidad del aire).
- Construir un modelo predictivo basado en ML que determine directamente la temperatura de aire óptima (T_a) que garantiza un PMV en confort.
- Cuantificar el impacto de omitir las variables personales (`clo`, `met`) sobre la precisión de la estimación.
- Evaluar el desempeño del modelo mediante métricas estadísticas y análisis de sensibilidad, verificando su robustez operativa frente a variaciones ambientales y estados de actuadores.

II. Estado del Arte

El control del confort térmico en edificios inteligentes es un problema ampliamente estudiado. La literatura reciente se centra en cómo predecir y controlar el Voto Medio Previsto (PMV) utilizando datos de sensores IoT.

1) **Control basado en Lógica Difusa (Fuzzy Control):** El trabajo de Sung & Hsiao (2020) [7] presenta un sistema basado en IoT que utiliza *Fuzzy Control* para regular el PMV según la norma ISO 7730. El sistema ajusta el HVAC (aire acondicionado, ventilador, etc.) para mantener el confort. Si bien demuestra ser funcional, su principal limitación es que utiliza valores fijos por defecto (*default values*) para las variables personales clave: 1.2 met para metabolismo y 0.6 clo para ropa, ignorando la variabilidad del ocupante.
2) **Modelos Predictivos con Machine Learning (ML):** El estudio de Boutahri & Tilioua (2024) [2] se enfoca en la *predicción* del PMV, comparando cuatro algoritmos de ML. Demuestran que Random Forest (RF) y XGBoost (XGB) son altamente eficaces para estimar el PMV (con $R^2 > 0.96$) cuando se dispone de las seis variables (ambientales y personales). Este trabajo valida el potencial de ML para modelar el confort, pero no implementa un lazo de control directo.
3) **Control Adaptativo con Aprendizaje por Refuerzo (RL):** Rajuroy (2024) [5] propone un enfoque más avanzado usando *Reinforcement Learning* (RL). El objetivo es que un agente de IA aprenda la política óptima para balancear confort y energía, utilizando sensores de ocupación como *proxy* de la actividad. Aunque es conceptualmente robusto y adaptativo, su implementación es computacionalmente compleja y no

resuelve explícitamente la captura de la variable de ropa (`clo`).

La Tabla I resume el benchmarking de estas soluciones representativas del estado del arte, identificando sus principales limitaciones.

TABLE I
BENCHMARK DE SOLUCIONES DEL ESTADO DEL ARTE

Paper	**Enfoque de Control**	**Limitación (Gap) Identificada**
Sung & Hsiao [7]	Control Difuso (Fuzzy)	No es adaptativo. Usa valores fijos para `clo` y `met`.
Boutahri et al. [2]	Predicción ML (RF, XGB)	Es un modelo predictivo, no de control. No resuelve el "modelo inverso".
Rajuroy [5]	Aprendizaje por Refuerzo (RL)	Alta complejidad. Resuelve `met` (con ocupancia) pero no `clo`.

III. ARQUITECTURA DEL SISTEMA

Para la implementación de la solución propuesta, se ha diseñado una arquitectura IoT modular dividida en cuatro capas bien diferenciadas. Este enfoque por capas permite desacoplar la adquisición física de datos de la lógica de negocio y la interfaz de usuario, facilitando la escalabilidad y el mantenimiento del sistema. La estructura general se ilustra en la Fig. 1.

Fig. 1. Diagrama de la arquitectura de 4 capas propuesta: Obtención de datos, Comunicación, Soporte y Aplicación.

A continuación, se detalla la función y composición de cada capa, desde el nivel físico hasta el nivel de aplicación:

A. Capa 1: Obtención de Datos (Percepción)

Esta capa constituye el nivel físico del sistema y es responsable de la interacción directa con el entorno. Su función principal es la recolección de variables ambientales en tiempo real y la ejecución de comandos físicos.

- **Sensores y Actuadores:** Se utiliza el módulo sensor DHT22 (AM2302)[1] para la medición precisa de temperatura y humedad. Además, se integran dispositivos IoT comerciales, como motores de cortinas y sensores de contacto magnético.
- **Unidad de Procesamiento Local:** Un microcontrolador ESP32-C6 [4] actúa como nodo coordinador local, encargado de leer los sensores y gestionar los estados de los actuadores.

B. Capa 2: Comunicación (Red)

Esta capa garantiza el transporte seguro, robusto y eficiente de los datos entre la capa física y la capa de procesamiento.

- **Protocolo Zigbee:** Se ha seleccionado Zigbee 3.0 como estándar de comunicación debido a su bajo consumo energético y su capacidad para formar redes en malla (*mesh*). Esto asegura que la red de sensores del hogar inteligente (Smart Home) mantenga la conectividad incluso si un nodo intermedio falla, optimizando el alcance y la fiabilidad de la transmisión de datos.

C. Capa 3: Soporte (Procesamiento y ML)

Representa el núcleo inteligente o "cerebro" del sistema. En esta capa reside la lógica de negocio y los algoritmos de Machine Learning desarrollados.

- **Modelo Inverso (Decision-Making):** Aquí se ejecutan los modelos predictivos (XGBoost) entrenados. El sistema procesa las entradas recibidas (Humedad, Velocidad del aire, Ropa, Metabolismo) y calcula dinámicamente la temperatura objetivo (T_{out}) necesaria para alcanzar el confort térmico (PMV ≈ 0).
- **Gestión de Datos:** Se encarga del almacenamiento temporal de lecturas y la preparación de los vectores de características para el modelo de ML.

D. Capa 4: Aplicación (Interfaz)

Es la capa superior con la que interactúa el usuario final.

- **Dashboard Interactivo:** Se despliega una interfaz gráfica que visualiza el estado actual del confort térmico, las variables ambientales medidas y las recomendaciones del sistema. Permite al usuario supervisar el funcionamiento del modelo automático y, si es necesario, intervenir manualmente.

IV. METODOLOGÍA Y DESARROLLO DEL MODELO PREDICTIVO

V. METODOLOGÍA

La estrategia metodológica se diseñó para abordar el problema del confort térmico desde una perspectiva de "Decision-Making" basada en datos. A diferencia de los lazos de control clásicos (PID), que reaccionan al error instantáneo, este enfoque utiliza aprendizaje supervisado para estimar el punto de operación óptimo del sistema. El desarrollo se estructuró en cuatro fases: preprocesamiento de datos, formulación matemática del modelo inverso, configuración del algoritmo y validación.

A. Adquisición y Preprocesamiento de Datos

Se utilizó el *ASHRAE Global Thermal Comfort Database II*, la base de datos más extensa en la literatura de confort térmico. El conjunto de datos original contiene mediciones heterogéneas, por lo que se aplicó un filtrado riguroso para garantizar la calidad del entrenamiento:

1) **Selección de Características (Feature Selection):** Se extrajeron las seis variables fundamentales que componen la ecuación de Fanger: Temperatura del aire (T_a), Temperatura radiante media (T_{rm}), Humedad relativa (RH), Velocidad del aire (v_a), Aislamiento de la ropa (clo) y Tasa metabólica (met).
2) **Limpieza de Datos:** Se eliminaron registros con valores nulos o físicamente inconsistentes (e.g., $RH > 100\%$, $clo < 0$).
3) **Normalización:** Aunque los modelos basados en árboles son robustos a escalas variadas, se verificó la distribución de las variables para asegurar que cubrieran rangos operativos típicos de un hogar (e.g., $T_a \in [15, 35]^\circ C$).

B. Formulación del Modelo Inverso

El aporte central de esta metodología es la inversión de la función de confort. El modelo PMV tradicional se define como una función f:

$$PMV = f(T_a, T_{rm}, v_a, RH, met, clo) \tag{1}$$

Para propósitos de control, el objetivo es encontrar la temperatura del aire necesaria (T_{target}) para alcanzar un PMV deseado (típicamente 0, neutralidad térmica). Dado que la ecuación de Fanger es altamente no lineal y compleja de despejar analíticamente en tiempo real, se aproximó la función inversa f^{-1} mediante Machine Learning:

$$T_{target} \approx \hat{f}^{-1}(PMV_{ref}, T_{rm}, v_a, RH, met, clo) \tag{2}$$

Durante el entrenamiento, la variable objetivo ($target$) fue la temperatura del aire (T_a) registrada en la base de datos, mientras que el PMV calculado se utilizó como una variable de entrada ($feature$), forzando al modelo a aprender la relación inversa.

Se hizo uso de los modelos **XGBoost (Extreme Gradient Boosting)**[3] y Random Forest [6] debido a su eficiencia computacional y capacidad de regularización interna ($L1/L2$), crítica para evitar el sobreajuste en datasets tabulares.

La configuración de hiperparámetros se optimizó no solo para minimizar el error, sino para garantizar la generalización del modelo ante nuevos usuarios. Los parámetros finales, definidos en el entorno de desarrollo, son:

- **Objective = 'reg:squarederror':** Se optimiza el Error Cuadrático Medio, penalizando grandes desviaciones en la temperatura predicha.
- **n_estimators = 200:** Número de árboles de decisión secuenciales. Se determinó empíricamente que, por encima de 200, la ganancia marginal en precisión no justificaba el costo computacional adicional.
- **max_depth = 6:** Profundidad máxima de cada árbol. Un valor de 6 permite capturar interacciones complejas (como la relación no lineal entre humedad y temperatura) sin memorizar el ruido del set de entrenamiento.
- **learning_rate (η) = 0.05:** Una tasa de aprendizaje baja (reducción del aporte de cada árbol) para asegurar una convergencia suave hacia el mínimo global del gradiente.
- **subsample / colsample_bytree = 0.8:** Técnica de *bagging* estocástico; cada árbol se entrena con el 80% de los datos y el 80% de las características seleccionadas aleatoriamente, aumentando la robustez del modelo frente a valores atípicos.

C. Estrategia de Entrenamiento y Validación

El conjunto de datos se dividió utilizando la técnica de *Hold-Out Validation* con una proporción 80/20 (80% entrenamiento, 20% prueba), asegurando que el set de prueba (X_{test}) nunca fuera visto por el modelo durante el ajuste de pesos. Se fijó una semilla aleatoria (*random_state=42*) para garantizar la reproducibilidad de los experimentos.

Las métricas de evaluación seleccionadas fueron el Coeficiente de Determinación (R^2) para medir la bondad de ajuste y la Raíz del Error Cuadrático Medio ($RMSE$) para cuantificar el error en grados Celsius, métrica directa para la interpretación física del control térmico.

VI. Gap Tecnológico y Oportunidad

El análisis del estado del arte (Tabla I) revela un "gap" tecnológico claro y una oportunidad de innovación. El problema central no resuelto es la **gestión de las variables personales** (`met` y `clo`) en un lazo de control práctico.

A. Análisis Crítico

Los sistemas actuales caen en dos categorías con problemas opuestos:

- **Sistemas de Control (ej. Fuzzy [7]):** Son funcionalmente simples de implementar, pero logran el control a costa de la precisión, asumiendo que el usuario es un "maniquí" estático con ropa y actividad constantes.
- **Sistemas Predictivos (ej. ML/RL [2, 5]):** Son computacionalmente avanzados y precisos, pero no resuelven trivialmente el problema del control (el "modelo inverso").

B. El Problema No Resuelto (El Gap)

El "gap" tecnológico es la falta de un sistema que sea, simultáneamente, **preciso y práctico**. Los sistemas de control actuales *ignoran* el impacto de las variables `clo` y `met`, y no se ha cuantificado rigurosamente *cuánto error* introduce esta simplificación.

1) **Cuantificar el Gap:** Utilizar la precisión de los modelos de ML (como XGBoost [2]) para realizar un benchmark que demuestre numéricamente la caída de rendimiento al omitir `clo` y `met`.
2) **Proponer una Solución:** Desarrollar un "modelo inverso" basado en ML que utilice las seis variables (asumiendo que `clo` y `met` pueden ser entradas del

usuario) para determinar la temperatura de consigna (T_a), cumpliendo el objetivo del proyecto.

VII. Variantes de Solución

Para abordar el "gap" y determinar el mejor modelo base para un futuro sistema de control, se evaluaron tres variantes de solución basadas en Machine Learning. El objetivo de este benchmark es seleccionar el modelo de regresión más preciso para predecir el PMV.

A. Alternativas Evaluadas

Las tres variantes se entrenaron y evaluaron siguiendo la metodología descrita en el Hito 1, utilizando el dataset "ASHRAE Global Thermal Comfort Database II".

1) **Variante 1: Ridge Regression:** Un modelo lineal simple pero robusto, regularizado (L2) para prevenir el sobreajuste. Requiere escalado de datos (`StandardScaler`). Figuras (4) (5)
2) **Variante 2: Random Forest (RF) [6]:** Un modelo de ensamblaje (ensemble) no lineal, basado en árboles de decisión. Configurado con hiperparámetros (`max_depth=8`) para controlar su complejidad. Figuras (6) (7)
3) **Variante 3: XGBoost (XGB):** Un modelo avanzado de Gradient Boosting, reconocido por su alto rendimiento en competiciones. Configurado con hiperparámetros (`max_depth=6`, `learning_rate=0.05`). Figura (8) (9)

B. Criterios de Comparación y Tabla

Los criterios de selección fueron la precisión predictiva (R^2), el error de predicción (RMSE) y la capacidad del modelo para identificar las variables más importantes (*Feature Importance*). Cada variante se probó en dos escenarios: (A) **Full Model**, usando las 6 variables (`ta`, `tr`, `rh`, `vel`, `met`, `clo`), y (B) **Reduced Model**, usando solo las 4 variables ambientales. La Tabla II resume los resultados.

TABLE II
Comparativa de Variantes de Solución (Resultados en Test Set)

Variante	Full Model (6 vars)		Reduced Model (4 vars)	
	R^2	RMSE	R^2	RMSE
1. Ridge	0.7510	0.3743	0.5216	0.5188
2. RF	0.8877	0.2513	0.6559	0.4400
3. XGBoost	**0.9614**	**0.1474**	**0.6618**	**0.4362**

Ahora si bien, posterior a esto se realizaron otras pruebas con el algoritmo Random Forest. En este caso se hizo uso de las siguientes variables:

- **tr** (Mean Radiant Temperature): Temperatura radiante media, medida generalmente en °C. Representa el calor promedio irradiado por las superficies del entorno.
- **rh** (Relative Humidity): Humedad relativa (%). Cantidad de vapor de agua presente en el aire.
- **vel** (Air Velocity): Velocidad del aire (m/s).
- **pmv_ce** (Predicted Mean Vote – Cooling Effect): Índice de confort térmico de Fanger ajustado por el efecto de enfriamiento del aire.
- **blind_curtain**: Variable de estado para las persianas o cortinas (ej. 0/1 o porcentaje de apertura).
- **fan**: Estado del ventilador (Encendido/Apagado).
- **window**: Estado de la ventana (Abierta/Cerrada).
- **door**: Estado de la puerta (Abierta/Cerrada).
- **heater**: Estado del calentador o calefacción (Encendido/Apagado).

Esto, con el fin de predecir la temperatura T_a, a continuación se detallan los resultados obtenidos con el algoritmo de Random Forest:

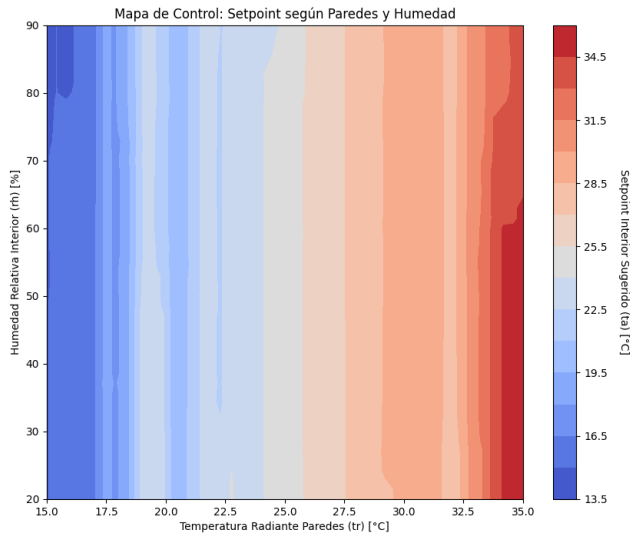

Fig. 2. Gráfica de Setpoint según Paredes y Humedad

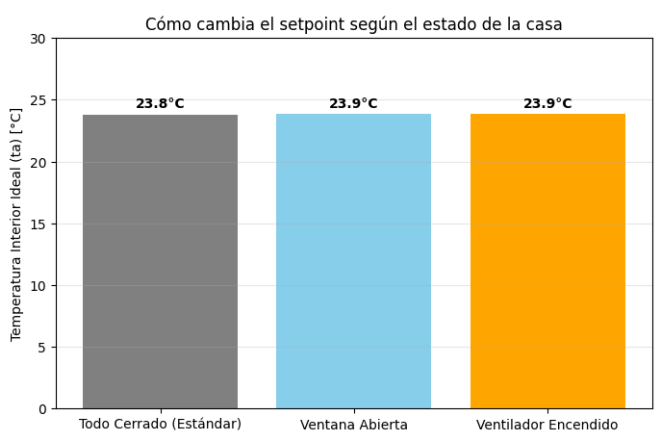

Fig. 3. Variación del Setpoint según estado de la casa

C. Evaluación del Controlador Interno

El rendimiento del controlador predictivo fue evaluado considerando precisión estadística, estabilidad operativa y respuesta ante variables termodinámicas.

1) Precisión y Métricas de Error: El modelo entrenado demostró una alta capacidad de generalización, alcanzando un coeficiente de determinación (R^2) de **0.9865**. El error cuadrático medio (RMSE) se situó en **0.4512 °C**. Este margen de error es inferior a la banda de histéresis típica de los termostatos comerciales (± 0.5°C), validando la viabilidad del controlador para aplicaciones de climatización en tiempo real sin introducir oscilaciones indeseadas.

2) Sensibilidad ante Actuadores (Escenarios): Se analizó la respuesta del *setpoint* sugerido ante cambios discretos en los actuadores (ventanas y ventilación mecánica). Como se observa en la Figura [3], el sistema mantiene una estabilidad robusta:

- El punto de consigna varió marginalmente entre **23.81 °C** (estado base: todo cerrado) y **23.92 °C** (ventana abierta).
- La activación del ventilador y el aumento de velocidad del aire (0.1 a 0.5 m/s) resultaron en una variación despreciable (< 0.1°C).

Estos resultados indican que el controlador prioriza la inercia térmica global sobre las perturbaciones instantáneas de flujo de aire para la definición del objetivo de temperatura.

3) Influencia de Variables Ambientales (Mapa de Control): El mapa de calor (Figura [2]) revela la lógica física aprendida por el modelo:

1) **Dominancia de la Temperatura Radiante (T_r):** Existe una correlación positiva fuerte entre T_r y el *setpoint* de aire (T_a). A medida que la temperatura de las superficies aumenta (eje X), el controlador eleva la temperatura objetivo del aire (gradiente azul a rojo). Esto sugiere un comportamiento compensatorio donde el sistema ajusta la temperatura del aire para equilibrar la carga radiante de las paredes.
2) **Desacoplamiento de la Humedad:** Las isotermas verticales indican que la Humedad Relativa (rh) tiene una influencia nula en la determinación del *setpoint* dentro del rango operativo estudiado ($20\% - 90\%$). El controlador opera independientemente de la carga latente, simplificando la lógica de control a una respuesta puramente sensible.

VIII. Discusión

A. Evolución del Enfoque: De PMV a Control Directo de Temperatura

El benchmark inicial evaluó tres variantes de ML (Ridge Regression, Random Forest y XGBoost) para predecir PMV usando variables ambientales y personales. Sin embargo, la fuerte dependencia de variables no medibles (`clo`, `met`) motivó un **cambio de paradigma**: predecir directamente la **temperatura de setpoint óptima** (Ta) usando variables medibles del entorno y estados de actuadores.

B. Comparación de Enfoques

Enfoque Inicial (Predicción de PMV): XGBoost alcanzó el mejor rendimiento con variables completas (R^2 = 0.9614), pero al eliminar `clo` y `met`, sufrió una caída de 30 puntos porcentuales ($R^2 \rightarrow 0.6618$). Random Forest mostró mayor estabilidad con solo 23 puntos de caída ($0.8877 \rightarrow 0.6559$), aunque ningún modelo logró precisión suficiente con solo variables ambientales.

Enfoque Final (Predicción de Ta): Utilizando variables operacionales (tr, rh, vel, pmv_ce, y estados de actuadores: *blind_curtain*, *fan*, *window*, *door*, *heater*), Random Forest alcanzó **R^2 = 0.9865** y **RMSE = 0.4512°C**, superando significativamente el mejor resultado del enfoque inicial.

C. Justificación de Random Forest

1) 1. Precisión y Estabilidad Operativa: El modelo alcanza **R^2 = 0.9865** con un **RMSE de 0.4512°C**. Para comprender estos resultados:

Coeficiente de Determinación (R^2):

- **Significado cualitativo**: Mide qué proporción de la variabilidad en la temperatura objetivo puede ser explicada por el modelo. Un valor cercano a 1 indica que el modelo captura prácticamente toda la variación real de los datos.
- **Interpretación cuantitativa**: R^2 = 0.9865 significa que el modelo explica el **98.65% de la varianza**. Solo un 1.35% queda sin explicar.
- **Implicación práctica**: El sistema puede anticipar con alta confiabilidad la temperatura óptima en función de condiciones ambientales y estados de actuadores.

Error Cuadrático Medio (RMSE):

- **Significado cualitativo**: Representa el error promedio en °C, penalizando fuertemente errores grandes.
- **Interpretación cuantitativa**: RMSE = 0.4512°C indica una desviación promedio de ± 0.45°C.
- **Implicación práctica**: El error es menor que la histéresis típica de termostatos (±0.5°C), evitando oscilaciones del sistema HVAC.

El análisis de sensibilidad complementa estas métricas: el setpoint varía solo entre 23.81°C y 23.92°C ante cambios en actuadores, con variaciones menores a 0.1°C por cambios en velocidad del aire. Esto garantiza operación sin oscilaciones.

2) Aprendizaje de Principios Termodinámicos: El mapa de calor (Figura 2) confirma que el modelo internalizó física subyacente:

- **Dominancia de Tr**: El setpoint se ajusta proporcionalmente a la temperatura radiante, compensando cargas radiantes.
- **Desacoplamiento de RH**: La humedad (20%–90%) no afecta el setpoint, simplificando el control a respuesta térmica sensible.

3) Robustez Validada: El benchmark inicial mostró que Random Forest fue 23% más estable que XGBoost ante ausencia de variables críticas. Esta propiedad es clave para un sistema donde la robustez es prioritaria.

IX. Conclusiones y Trabajo futuro

A. Conclusiones

Este trabajo identificó que la principal limitación de los sistemas actuales de confort térmico radica en la dependencia de las variables personales `clo` y `met`, imposibles de medir automáticamente en un hogar. El benchmark inicial

demostró que la predicción de PMV pierde hasta 30 puntos porcentuales de precisión al omitirlas, lo que la vuelve inadecuada para aplicaciones prácticas.

El cambio metodológico hacia la **estimación directa de la temperatura de aire óptima** permitió superar esta limitación. El modelo Random Forest entrenado con variables exclusivamente medibles obtuvo $R^2 = 0.9865$ y RMSE = $0.45°C$, lo que valida su capacidad para determinar la temperatura necesaria para mantener el PMV en confort sin depender de un lazo de control.

Así, se demuestra que es posible resolver el problema del confort térmico mediante un modelo puramente predictivo, capaz de entregar un valor óptimo de operación que puede ser utilizado por cualquier sistema HVAC, sea manual o automatizado.

B. Trabajo futuro

Los hallazgos de este hito validan la necesidad de avanzar hacia los objetivos específicos restantes del proyecto. El trabajo futuro se centrará en:

- Desarrollar el **modelo inverso**, entrenando un nuevo modelo Random Forest donde la salida sea la temperatura de consigna (T_a) y las entradas incluyan el PMV objetivo (0.0).
- Realizar la simulación completa del sistema para validar que puede mantener el PMV en el rango [-0.5, 0.5] bajo escenarios de usuario dinámicos, aprovechando la robustez del modelo seleccionado.
- Integrar un **controlador HVAC** basado en el modelo desarrollado, evaluando su desempeño bajo estrategias como control PID o MPC para comparar eficiencia energética y estabilidad térmica.
- Extender el análisis hacia **sensores de bajo costo** y robustez ante ruido, verificando que el modelo mantenga precisión operativa bajo mediciones imperfectas propias de instalaciones reales.

REFERENCES

[1] AliExpress. *DHT22 AM2302 Digital Temperature and Humidity Sensor Module*. https://www.aliexpress.com/item/32759901711.html. Accedido: Nov. 28, 2025. 2025.

[2] Youssef Boutahri and Amine Tilioua. "Machine learning-based predictive model for thermal comfort and energy optimization in smart buildings". In: *Results in Engineering* 22 (2024), p. 102148.

[3] Tianqi Chen et al. "Xgboost: extreme gradient boosting". In: *R package version 0.4-2* 1.4 (2015), pp. 1–4.

[4] Espressif Systems. *ESP32-C6-DevKitC-1 User Guide*. https://docs.espressif.com/projects/esp-dev-kits/en/latest/esp32c6/esp32-c6-devkitc-1/user_guide.html. Accedido: Nov. 28, 2025. 2025.

[5] Adam Rajuroy. "Adaptive Thermal Comfort Control in Smart Homes with Reinforcement Learning and IoT Sensors." In: ().

[6] Jaime Lynn Speiser et al. "A comparison of random forest variable selection methods for classification prediction modeling". In: *Expert systems with applications* 134 (2019), pp. 93–101.

[7] Wen-Tsai Sung and Sung-Jung Hsiao. "The application of thermal comfort control based on Smart House System of IoT". In: *Measurement* 149 (2020), p. 106997.

X. Anexos

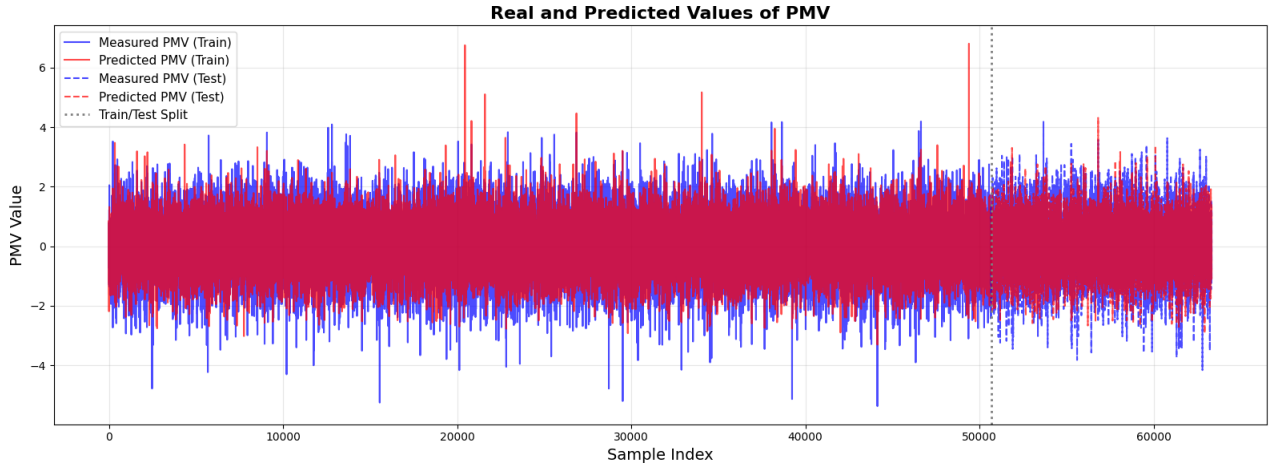

Fig. 4. Linear Regressor Ridge 6 variables

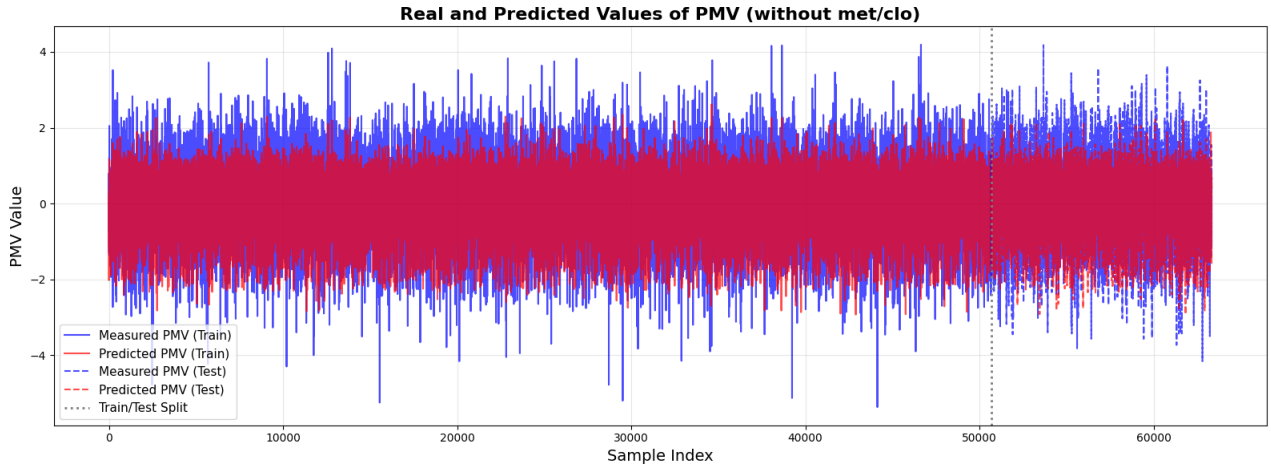

Fig. 5. Linear Regressor Ridge 4 variables

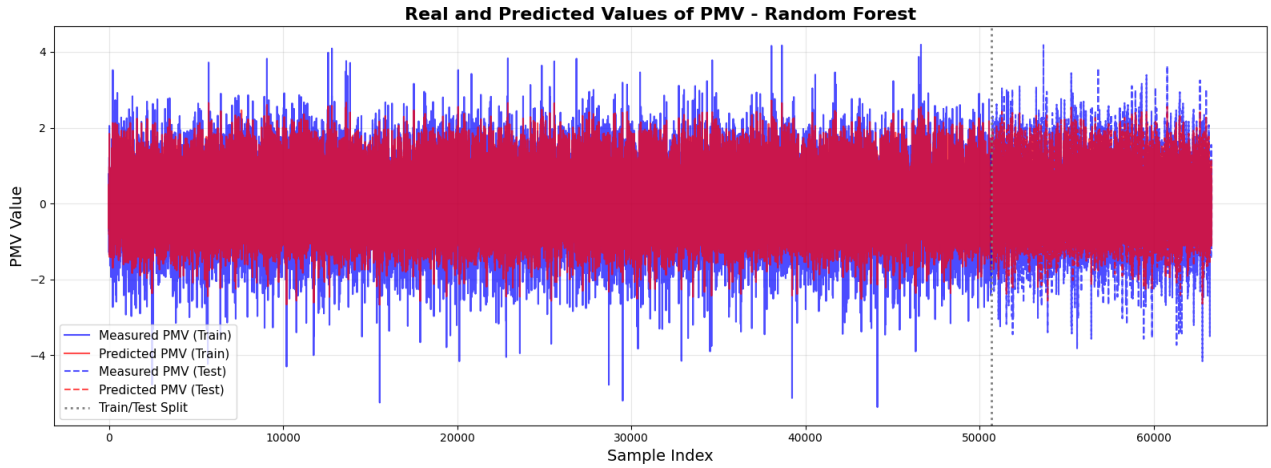

Fig. 6. Random Forest 6 variables

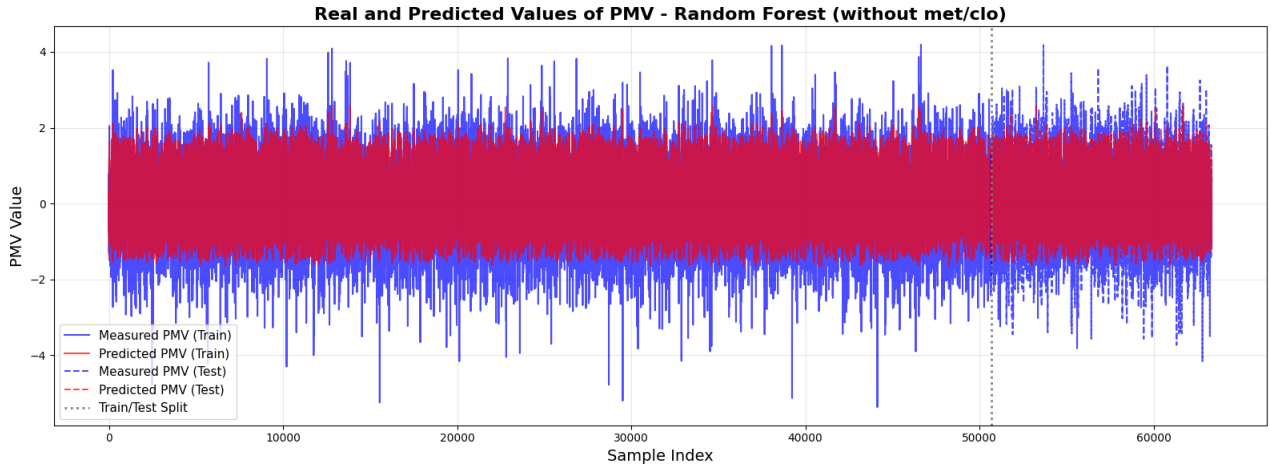

Fig. 7. Random Forest 4 variables

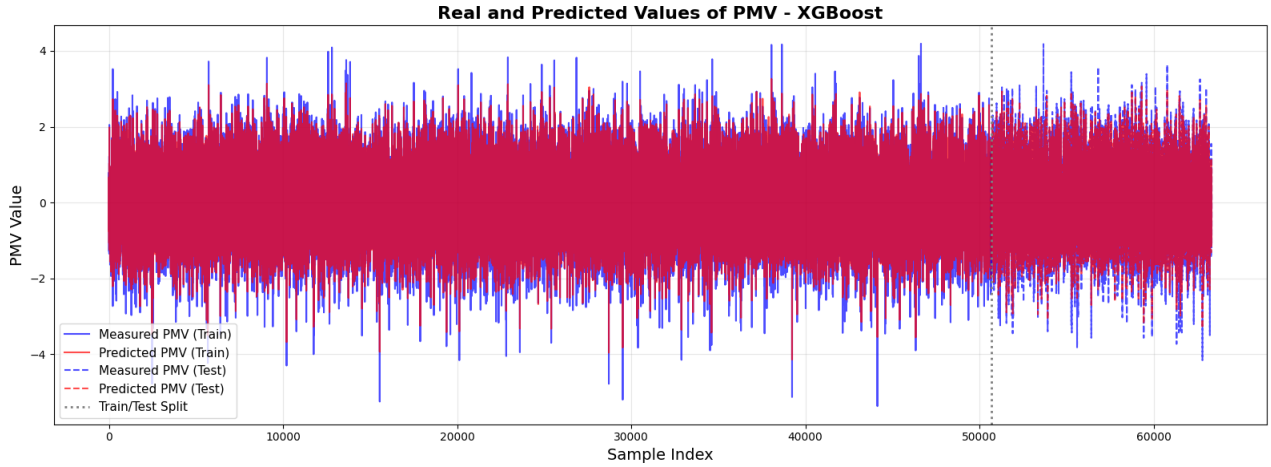

Fig. 8. Xg-Boost 6 variables

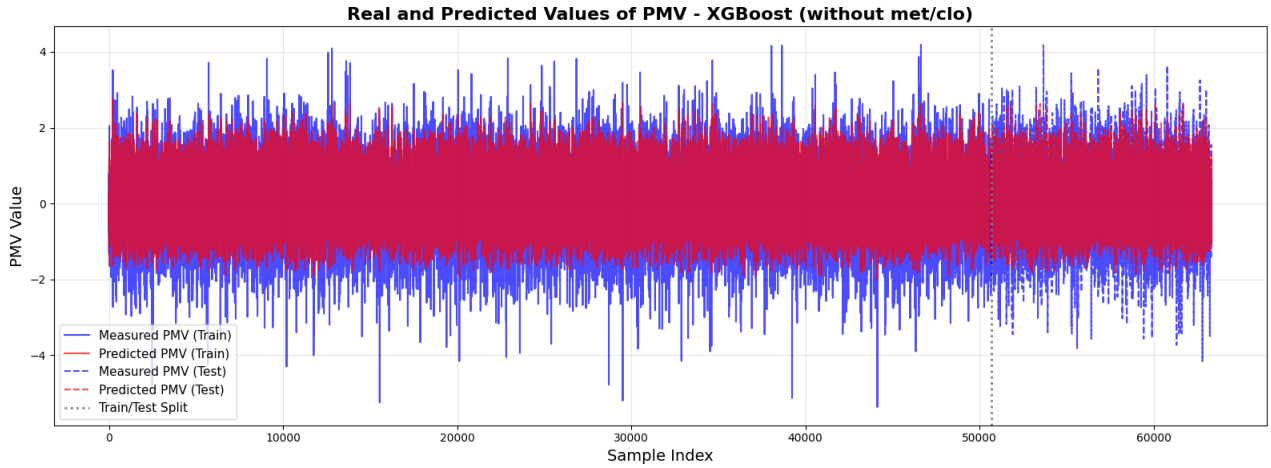

Fig. 9. Xg-Boost Ridge 4 variables